

DS-MINI_2반_백세희+이미주_251014

1. 문제 정의

Steel Plates Faults 데이터셋은 강철판 제조 과정에서 발생하는 7가지 결함 유형을 분류하는 다중 클래스 문제이다. 그러나 각 결함은 발생 원인과 형태가 상이하며, 광학적 요인, 물리적 요인, 위치적 요인등이 복합적으로 작용한다. 따라서 단일 변수로는 결함을 충분히 설명하기 어렵고, Feature 간의 상관관계와 비선형적 상호작용을 함께 고려해야 한다.

이에 본 보고서는 결함별 주요 Feature의 통계적 관계와 모델 기반 영향도를 종합적으로 분석하여 각 결함의 발생 메커니즘을 규명하고, 향후 결함 자동 분류 모델 설계에 필요한 Feature 선택 및 모델링 전략의 근거를 마련하고자 한다.

1-1. 데이터 개요

Dataset: Steel Plates Faults (UCI Repository)

Shape: (1,941 × 34)

Feature 수: 27개

Target 수: 7개 (One-Hot Encoding 구조)

결측치: 없음

- 결함 발생 원인 변수 설명

그룹	주요 변수	의미
위치/크기 관련	X/Y_Min/Max, Pixels_Areas, Perimeter, Sum_of_Luminosity	결함의 위치, 면적, 둘레, 밝기 총량
형상 관련 (Shape)	Orientation_Index, LogOfAreas, Log_X/Y_Index, SigmoidOfAreas	결함의 방향, 기울기, 비율, 형태 복잡도
밝기 관련	Minimum/Maximum/Luminosity_Index	표면 밝기와 반사율
강판 종류 관련	TypeOfSteel_A300/A400, Steel_Plate_Thickness	재질 특성, 두께

1-2. 이상치 확인

IQR 사분위수 범위를 기준으로 이상치를 탐지한 결과, 가장 이상치가 많은 변수는 조도 관련 변수 (Sum_of_Luminosity)와 결함 면적관련 변수(Pixels_Areas)로 보여진다.

이는 결함의 밝기와 크기 차이가 매우 큰 샘플이 존재하며 단순 오류 보다는 결함 유형에 따른 물리적인 차이일 가능성이므로 판단했다. 따라서 해당 이상치를 제거하기 보다는 이상치에 강한 알고리즘을 사용하고자 한다. (부록 표 1)

2-1. 결함 유형 분포

결함 유형은 다음과 같다.

결함 유형	설명
Pastry	표면에 나타나는 둥근 얼룩 형태의 결함 (국부적 불균일)
Z_Scratch	Z자 모양의 긁힘, 가공·운송 중 접촉으로 발생
K_Scratch	K자 형태의 긁힘, Z_Scratch와 유사하나 모양이 다름

결함 유형	설명
Stains	화학 반응·습기 등으로 인한 국소적 얼룩·오염 자국
Dirtiness	표면 전반에 걸친 더러움·이물질 부착, 불규칙적 패턴
Bumps	압연 불량·불순물로 인한 돌출(튀어나온) 결함
Other_Faults	위 6가지로 분류되지 않는 기타 결함 (균열, 잡음 등 포함)

결함 유형별 샘플 분포를 분석한 결과는 다음과 같다. Other_Faults(673건, 36.4%)가 압도적으로 많은 비중을 차지하며, Bumps(402건, 21.7%)와 K_Scratch(391건, 21.1%)가 그 뒤를 따른다. 중간 규모 클래스로는 Z_Scratch(190건, 10.3%)와 Pastry(158건, 8.5%)가 있으며, Stains(72건, 3.9%)와 Dirtiness(55건, 3.0%)는 극소수 클래스에 해당한다. 최대 클래스와 최소 클래스 간 샘플 수 비율은 12.2:1로, 일반적으로 클래스 불균형 문제로 간주되는 10:1 기준을 초과하고 있어 모델 학습에 있어 특별한 대응 전략이 필요함을 시사한다. (부록 표 2)

데이터 불균형 원인 분석

Other_Faults가 전체의 1/3 이상을 차지하는 이유는 해당 범주가 "기타 결함"이라는 포괄적 성격을 지니기 때문이다. 이는 실무적으로 불가피한 선택이지만, 모델링 관점에서는 내부적으로 이질적인 샘플들이 하나의 클래스로 묶여 있어 명확한 패턴 학습이 어려울 수 있다는 문제를 내포한다.

Dirtiness는 55건, Stains는 72건으로 소수 클래스이다. 샘플 수가 적은 원인은 크게 두 가지로 추정된다. 첫째, 육안 라벨링 과정의 한계이다. 오염, 얼룩은 명확한 물리적 경계가 없어 판단 기준이 모호하다. 따라서 센서나 이미지 데이터에서도 뚜렷한 신호로 포착되기 어렵고 작업자의 주관이 많이 들어간다. 둘째, 실제 제조 공정에서의 낮은 발생 빈도이다. 현대 강철판 제조 공정은 청결도 관리가 철저하여 육안으로 확인 가능한 수준의 오염 결함은 드물게 발생한다.

2-2. 결함 유형별 Feature 특징

각 결함이 어떤 특성 feature과 관계가 있는 지 다양한 평가 요소를 활용해 복합적으로 확인하였다.

첫째, Pearson 상관분석을 통해 결함과 특성간의 선형 관계를 파악하고 결함 발생에 미치는 영향 방향성과 강도를 파악하였다. 둘째, Random Forest Feature Importance를 계산하여 비선형 관계를 포함한 예측 기여도를 평가하였다. 셋째, Permutation Importance를 통해 선형과 비선형 관계를 함께 확인하고자 했다. 변수 간 다중공선성에 덜 민감하여 보다 신뢰할 수 있는 중요도 평가를 제공한다.

우선 Pastry 결함은 표면의 방향성과 형상 불균일, 밝기 차이에 의해 발생하는 경향을 보였다. 주요 변수는 *Orientation_Index*, *Edges_Y_Index*, *Square_Index*이며, 약한 선형성과 비선형적 상호작용이 공존한다.

Z_Scratch 결함은 강판의 재질(*TypeOfSteel*), 공정 길이(*Length_of_Conveyer*), 위치 좌표(*X_Min/Max*), 두께(*Steel_Plate_Thickness*)와 관련이 깊었다. 긁힘은 주로 특정 재질과 구간에서 집중적으로 발생하며, 선형과 비선형 관계가 동시에 존재한다.

K_Scratch 결함은 *Log_X_Index*, *Outside_X_Index*, *LogOfAreas*, *Luminosity* 등 위치 및 면적 관련 변수가 강한 영향을 미쳤다. 특히 X축 방향과 가장자리 근처에서 스크래치가 집중되는 비선형적 패턴이 뚜렷하다.

Stains 결함은 *LogOfAreas*, *Pixels_Areas*, *Sum_of_Luminosity*, *Edges_Index* 등 밝기와 면적, 형상 복잡도에 의해 발생하였다. 전반적으로 약한 선형 관계와 비선형적 영향이 공존한다.

Dirtiness 결함은 표면의 복잡한 구조적 특성에 의해 발생하는데, *Edges_Index*, *X_Min/Max*, *Orientation_Index*, *Square_Index* 등이 주요 변수로 작용했다. 결함은 표면의 거칠기, 기울기 변화, 형상 불균일성과 약한 선형 및 비선형 관계를 보인다.

Bumps 결함은 *Length_of_Conveyer*, *Square_Index*, *TypeOfSteel*, *Steel_Plate_Thickness* 등 공정 구간의 물리적 요인과 형상 지표가 주요 원인으로 나타났다. 선형성과 비선형성이 혼합된 패턴을 보인다.

마지막으로 Other_Faults 결함은 두께(*Steel_Plate_Thickness*)와 밝기(*Luminosity*) 관련 변수가 주요 요인으로, 비교적 단순한 선형적 관계를 보였다.

2-3. 다중공선성 및 상관성 분석 결과

상관관계 분석 (Feature Correlation)

전체 피쳐 간 상관계수 행렬을 통해 다중공선성 가능성을 확인한 결과, **X_Minimum-X_Maximum**, **Y_Minimum-Y_Maximum**, **X_Perimeter-Sum_of_Luminosity**, **Pixels_Areas-Sum_of_Luminosity**, **TypeOfSteel_A300-TypeOfSteel_A400** 등 일부 피쳐 쌍이 $|r| > 0.9$ 수준으로 매우 높은 양의 상관성을 보였다.

특히 X_와 Y_ 축 관련 변수 및 면적·둘레·밝기와 관련된 변수들이 거의 동일한 물리적 의미를 공유하는 중복 특성을 보였다.

이러한 상관성이 모델 학습 시 가중치 왜곡, 과적합 위험을 유발할 가능성이 높다고 판단되었다.

Point-Biserial Correlation (결함별 피쳐 연관성)

결함 유형별로 각 피쳐가 클래스(결함 발생 유무)에 미치는 선형 상관성을 파악하였다.

- 주요 결함별 상관도($|r_{pb}|$ 기준 상위 5개)

	K_Scratch : Log_X_Index, LogOfAreas, Outside_X_Index → 밝기·윤곽 관련 변수와 높은 상관
	Z_Scratch : TypeOfSteel_A400, TypeOfSteel_A300, X/Y_Maximum → 재질 및 치수 변수 영향
	Pastry : Orientation_Index, Outside_Global_Index → 방향성·외곽지수 영향
	Bumps : TypeOfSteel_A300/A400, Square_Index → 재질 및 형태 관련
	Stains : Log_Y_Index, LogOfAreas → 면적·위치 지표 관련
	Other_Faults : Steel_Plate_Thickness, Minimum_of_Luminosity → 판 두께·밝기 변수 관련

전반적으로 **형태·면적·밝기·재질**이 결함 유형별 분류에 중요한 피쳐로 나타났다.

공선성 의심 변수 검출 ($|r| > 0.90$ 기준)

다중공선성이 의심되는 피쳐 쌍은 총 **7쌍**으로 확인되었다. 제거 기준은 pair 중 $|r_{pb}|$ 이 더 낮은 피쳐를 제거하는 방식을 적용하였다. 설명력 기여도가 낮은 피쳐를 중심으로 제거하여 모델의 안정성과 해석력 향상을 도모하였다.

제거 대상 피쳐: ['Pixels_Areas', 'TypeOfSteel_A300', 'X_Maximum', 'X_Perimeter', 'Y_Maximum', 'Y_Perimeter']

VIF (Variance Inflation Factor) 다중공선성 진단

잔여 피쳐의 다중공선성 정도를 수치적으로 평가한 결과, 일부 변수(LogOfAreas, Log_X_Index, Log_Y_Index)에서 **VIF 값이 3000~8000 수준으로 매우 높게 측정**되어 다중공선성 영향이 확인되었다. 일반적으로 **VIF > 10**이면 다중공선성이 심각하다고 보므로, 이 세 변수는 최우선 제거 후보로 지정되었다.

결론 (Feature Selection Summary)

상관계수 + Point-Biserial + VIF 분석을 종합적으로 고려한 결과, 아래 피쳐들이 중복·공선성 및 낮은 중요도로 인해 최종 제거 대상으로 선정되었다.

```
['Pixels_Areas', 'TypeOfSteel_A300', 'X_Maximum', 'Y_Maximum',  
'X_Perimeter', 'Y_Perimeter', 'LogOfAreas', 'Log_X_Index', 'Log_Y_Index']
```

이 과정에서 전체 피쳐 수는 약 25% 감소, 제거 후 데이터셋은 주요 결함별 핵심 변수(밝기, 윤곽, 재질, 판 두께 등)를 중심으로 더 설명력 있고 다중공선성이 완화된 구조로 정제되었다.

4. 모델링 접근 전략 수립

Multi & Imbalance Classes :

본 보고서의 Steel Plate Faults 데이터는 결함 유형 간 라벨 불균형(Class Imbalance) 이 심한 다중 분류 문제로, Other_Faults 클래스가 673건(전체의 약 70%) 으로 매우 많은 반면, Dirtiness 클래스는 55건(약 5%) 에 불과하다.

이는 사람이 육안으로 오염 결함을 정확히 구분하기 어려워, 데이터 수집 및 라벨링 과정에서 발생한 불균형으로 추정된다.

이러한 구조적 불균형을 완화하기 위해 다음과 같은 학습 전략을 적용하였다.

1. 데이터 분할:

불균형이 심한 클래스 비율을 유지하기 위해 **Stratified Train-Test Split** 및 **Stratified K-Fold Cross Validation**을 사용하였다.

2. 데이터 증강:

소수 클래스 보안을 위해 **SMOTE(Synthetic Minority Over-sampling Technique)** 를 기본 적용하였고, 과적합이 관찰되는 경우에는 **SMOTETomek(Over + Under Hybrid Sampling)** 으로 대체하였다.

3. 평가 지표:

데이터 불균형 상황에서 전체 정확도(Accuracy)는 왜곡될 수 있으므로, 각 클래스의 성능을 균등하게 반영하는 **Macro-F1** 을 주 평가 지표로 사용하였다.

이로써 희귀 결함 클래스의 학습 기회를 확대하고, 모델의 균형된 일반화 성능을 확보할 수 있었다.

Feature Engineering :

이번에 제거된 변수들은 모두 물리적으로 중복되거나 서로 강하게 상관된 피쳐들이며, 이미 데이터 내의 다른 변수들이 그 의미를 충분히 대체하고 있다. 예를 들어 면적 관련 변수(Pixels_Areas, LogOfAreas)는 밝기와 면적 특성을 동시에 반영하는 Luminosity 지표들로 보완되고, 재질 변수(TypeOfSteel_A300)는 A400 변수로 대체 가능하다. 또한 X/Y 좌표와 둘레 관련 변수들은 동일한 공간적 정보를 가지므로 제거해도 결함 분류에 필요한 핵심 패턴에는 영향을 주지 않는다. 따라서 이번 Feature Engineering 과정은 실질적인 정보 손실 없이 중복성과 다중공선성을 완화하여 모델의 해석력과 안정성을 높인 타당한 조치로 판단된다.

Modeling :

Pearson 상관계수(선형성), RandomForest Feature Importance(비선형성), Permutation Importance(종합 기여도)를 함께 고려하여 결함-특성(feature) 간의 관계 구조를 복합적으로 해석 하였다.

- 결함별 관계 유형 요약
 - **선형적 패턴이 뚜렷한 결함:** *Other_Faults, K_Scratch*
두께(Thickness), 밝기(Luminosity) 등의 변수와 명확한 방향성 보이며 단순 선형 모델로도 설명이 가능하다.
 - **혼합형 관계:** *Pastry, Z_Scratch, Bumps*
Pearson은 중간, RF 중요도는 높게 나타나 선형+비선형이 공존한다. 선형성과 비선형성을 함께 학습할 수 있는 **Stacking(LR + XGBoost)** 적합하다.
 - **비선형 중심 결함:** *Stains, Dirtiness, 일부 K_Scratch*
낮은 상관계수에도 불구하고 RF/Permutation 중요도 높다. 트리 기반 모델이 변수 간 상호작용을 잘 포착한다.

전체 결함 중 **비선형 또는 혼합형 관계가 71% 이상**을 차지하기 때문에 바닐라 모델은 비선형 변수에 강한 XGBoost를 우선으로 채택한다. 그러나 선형, 비선형, 혼합형 관계로 이루어졌기 때문에 선형+비선형 모델을 모두 사용한 앙상블도 함께 고려하고자 한다.

5. Best Model 선정

실험 과정

1. Baseline 학습 (Vanilla 모델 비교)

- Logistic Regression, RandomForest, XGBoost를 각각 기본 설정으로 학습
- XGBoost가 가장 높은 Macro-F1(0.82)로 출발했으나 GAP이 크고 과적합 경향 존재
- Logistic은 해석 가능성은 높지만 불균형 클래스에서 Recall 저하

2. SMOTE / SMOTETomek 적용 (클래스 불균형 개선)

- 단순 SMOTE → 데이터 증폭 효과 확인
- XGBoost·RandomForest에 SMOTETomek(in-train) 적용하여 과샘플 및 노이즈 제거 병행
- GAP이 평균 0.18 → 0.13 수준으로 감소, Recall 균형 개선

3. 규제 강화 (Regularization)

- Ridge(L2) 규제를 Logistic에 적용
- C(규제 강도) = [0.05, 0.03, 0.02, 0.01] grid 탐색
- 규제 강도를 높일수록 과적합 억제 효과 뚜렷

4. Seed-Based Bagging (Seed Averaging)

- 동일 모델(XGB, RF)에 대해 5개 시드로 반복 학습 → 예측 확률 평균
- 분산 감소 및 모델 안정화 효과 확인
- GAP 감소 (예: XGB 0.18 → 0.13 → 0.05 수준까지 완화)

5. Soft Voting / Ensemble 실험

- XGBoost + RandomForest + Logistic 조합
- 교차검증(CV) 기반 가중치 적용 Soft Voting (Weighted Soft Voting Ensemble)
- Macro-F1은 향상되었으나 훈련 복잡도↑, GAP 감소 폭 제한적

6. 전처리 통합 및 GAP 기반 재평가

- 전 과정에서 다음 공통 전처리 파이프라인을 유지:
| Imputer(median) → Scaler(StandardScaler) → [SMOTE] → Model
- 모든 모델에 대해 Train-Test Macro-F1 및 GAP(소수점 6자리)을 계산
- GAP 기준 최적 모델 선별을 수행

모델 비교 성능 표

Section	Metric	Model A (XGBoost)	Model B (RandomForest)	Model C (RidgeLogit + SMOTE)	Model D: XGBoost + RandomForest + Logistic
SCORE	Macro-F1	0.824 ± 0.014	0.800 ± 0.013	0.601 ± 0.017	0.8338
	Accuracy	0.807	0.764	0.625	0.8072
	Weighted-F1	0.811	0.780	0.622	0.8088
	GAP (Train – Test)	0.134	0.157	0.0167 (최소)	0.1662
RECALL	Recall_Pastry	0.72	0.78	0.58	0.7037
	Recall_Zscratch	0.95	0.95	0.44	0.9091
	Recall_Kscratch	0.94	0.91	0.94	0.9359
	Recall_Stains	0.86	0.80	0.49	0.8000
	Recall_Dirtiness	0.91	0.83	0.53	0.5625
	Recall_Bumps	0.69	0.73	0.58	0.8571
	Recall_Others	0.71	0.64	0.77	0.9474
RUNTIME	Total Time (sec)	39.3	6.6	0.01	3.8002

• 모델 A (XGBoost)

- 전체 성능 지표 중 Macro-F1이 가장 높으나, GAP = 0.134 로 과적합 경향이 뚜렷.
- 학습 시간이 가장 길어 실시간 적용에는 부적합.

• 모델 B (RandomForest)

- 안정적인 성능을 보이거나 GAP = 0.157 로 여전히 과적합 존재.
- Recall이 비교적 고르게 분포하지만 학습시간이 중간 수준.

• 모델 C (RidgeLogit + SMOTE , C = 0.01)

- **GAP = 0.0167 로 최소**, 과적합이 가장 적음.

- SMOTE 적용으로 불균형 완화 및 안정된 일반화 성능 확보.
- Train Macro-F1 = 0.6178, Test Macro-F1 = 0.6011 로 Train-Test 간 성능 차 최소화.
- 학습/예측 속도도 0.01 sec 수준으로 가장 빠름.

• **모델 D (XGBoost + RandomForest + Logistic, Soft Voting 앙상블)**

- 세 가지 모델(XGBoost, RandomForest, RidgeLogit)의 **확률 출력을 가중 평균(Soft Voting)** 하여 결합한 앙상블 모델.
- 개별 모델들의 장점을 결합하여 **Macro-F1 = 0.8338, Accuracy = 0.8072** 로 가장 높은 예측 성능을 달성.
- 특히 **Recall_Zscratch(0.9474), Recall_Kscratch(0.9359), Recall_Dirtiness(0.9091)** 등 주요 결함 클래스의 재현율이 우수함.
- GAP = 0.1662 로 약간의 과적합은 존재하지만, 복합 모델 특성상 **전반적인 안정성과 균형 잡힌 성능**을 보임.

결론

여러 모델(XGBoost, RandomForest, Soft Voting 등)을 실험한 결과, 가장 높은 일반화 성능(GAP 최소)을 보인 모델은 **Ridge Logistic Regression + SMOTE(C=0.01)** 이었다.

복잡한 앙상블보다 단순한 규제형 선형 모델이 오히려 클래스 간 불균형 완화 + 과적합 억제에 효과적이었다. 특히 Macro-F1 기준에서 Train-Test 차이가 0.0167로, 모든 모델 중 가장 낮은 수준을 기록하며 과적합 없이 안정적인 분류 성능을 확보하였다.

⇒ **최종 Best Model은 RidgeLogit + SMOTE(C=0.01)**

6. 부록

표 1- 이상치 많은 순 시각화 자료




표 2 - 결합 유형 데이터의 불균형 분포를 확인할 수 있는 시각화 자료




표 3 - 결함별 Feature 관계 유형 관계 정리 표

결함별 Feature 관계 유형 (Linear / Non-Linear)

결함	주요 변수	Pearson 상관	RF 중요도	관계 유형	해석 요약
Pastry	Orientation_Index	+0.33	0.10	◆ 선형+약한 비선형	기울기 커질수록 결함↑ (명확한 방향성)
	Edges_Y_Index	+0.23	0.04	◆ 선형	엣지 수 많을수록 표면 불규칙 → 결함↑
	Square_Index	-0.24	0.05	◆ 비선형	균일도 낮은 구간에서 급격한 결함 증가
	Length_of_Conveyer	약함	0.07	◆ 비선형	특정 구간에서만 결함↑
	Empty_Index	약함	0.06	◆ 비선형	구간적 상호작용 존재
	Minimum_of_Luminosity	약함	0.05	◆ 비선형	밝기 임계값 영향 존재

결함 유형	주요 변수	Pearson 상관	RF 중요도	관계 유형	해석 요약
Z_Scratch	Length_of_Conveyer	-0.23	0.19	◆ 혼합형	짧을수록 마찰 집중 → 결함↑
	TypeOfSteel_A400	-0.34	0.09	◆ 선형	A400은 경도 높아 결함↓
	X_Maximum / X_Minimum	-0.26	0.09	◆ 비선형	위치에 따른 구간적 영향
	Steel_Plate_Thickness	약함	0.10	◆ 비선형	얇을수록 결함↑
K_Scratch	Log_X_Index	+0.74	0.14	◆ 비선형+중복	X위치 로그값 — 중복 영향 강함
	Outside_X_Index	+0.63	0.13	◆ 비선형+중복	가장자리 손상 집중

결함 유형	주요 변수	Pearson 상관	RF 중요도	관계 유형	해석 요약
	LogOfAreas	+0.70	0.12	◆ 비선형	면적 커질수록 결함↑, 곡선적 영향
	Sum_of_Luminosity	+0.62	0.09	◆ 비선형	밝기 높을수록 스크래치 뚜렷
	Minimum_of_Luminosity	-0.46	0.04	◆ 선형 약함	밝기 낮을수록 결함↑
Stains	LogOfAreas	-0.31	0.23	◆ 비선형	작은 면적에서 결함 집중
	Pixels_Areas	-0.07	0.17	◆ 비선형	넓은 구간에서 영향 변화
	Sum_of_Luminosity	-0.08	0.14	◆ 비선형	밝기 낮을수록 결함↑
	Edges_Index	+0.17	0.01	◆ 선형 약함	경계 많을수록 얼룩 복잡
Dirtiness	Edges_Index	+0.10	0.11	◆ 비선형	엣지 수↑ → 오염 확산 경향
	X_Minimum / X_Maximum	+0.10	0.08	◆ 약한 선형	위치 끝단에서 결함 집중
	Orientation_Index	+0.17	0.08	◆ 비선형	방향성 크면 더러움 퍼짐
	Square_Index	-0.21	0.06	◆ 선형 약함	균일도 낮을수록 오염↑
Bumps	Length_of_Conveyer	+0.23	0.09	◆ 비선형 혼합형	구간별 압력/열 영향
	Square_Index	+0.26	0.07	◆ 선형+비선형	균일도↑ → 돌출 증가
	TypeOfSteel_A300	+0.31	0.03	◆ 선형	연성 높은 A300에서 결함↑
	Steel_Plate_Thickness	약함	0.05	◆ 비선형	얇을수록 뒤틀림 발생
Other_Faults	Steel_Plate_Thickness	+0.32	0.10	◆ 선형	두께↑ → 결함↑ (명확한 직선형)
	Sum_of_Luminosity	-0.21	0.05	◆ 선형 약함	밝기↓ → 결함↑
	Minimum_of_Luminosity	+0.23	0.04	◆ 선형 약함	밝기 최소값↑ → 반사형 결함↑
	LogOfAreas / Pixels_Areas	-0.19	0.05	◆ 비선형 약함	작은 면적일수록 잡음 결함↑

9. Contribution

백세희: Target별 분포 차이 확인 및 시각화, 결함 유형별 Feature 특징 중요도 확인 및 상관 분석 진행, 모델링 전략 수립, 바닐라 및 앙상블 모델 최적화

이미주: 데이터의 class imbalance 고려한 모델링 전략 수립, 결함 유형별 Feature 특징 중요도 확인 및 상관 분석 진행, 바닐라 및 앙상블 모델 최적화